

Classificazione delle Regioni Europee per Livello di Sviluppo

Analisi di classificazione sui dati Eurostat NUTS-2 (2021)

Martina

2026-06-28

1 Introduzione

La politica di coesione dell'UE classifica le regioni NUTS-2 in tre categorie — *meno sviluppate*, *in transizione* e *più sviluppate* — in base al PIL pro capite (PPS) rispetto alla media UE, e assegna i fondi strutturali di conseguenza. **Obiettivo:** costruire un modello di classificazione che predica questa categoria usando indicatori socioeconomici *diversi dal PIL* (disoccupazione, istruzione, R&S, occupazione high-tech, banda larga) e valutarne la capacità predittiva su dati non visti.

Fonte. Dati **Eurostat**, anno 2021, livello NUTS-2, scaricati via API:

<https://ec.europa.eu/eurostat/api/dissemination/sdmx/2.1/data/{codice}>

Dataset utilizzati: `tgs00006` (PIL PPS, definisce la classe), `tgs00010`, `tgs00109`, `tgs00042`, `tgs00059`, `isoc_r_broad_h`. Il codice R completo è allegato come file separato (`R/01_load_data.R` – `R/04_evaluation.R`).

2 I Dati

Table 1: Predittori utilizzati (anno 2021, NUTS-2). Il PIL pro capite PPS definisce la classe e non è usato come predittore.

Variabile	Unità	Descrizione
<code>unemp_rate</code>	% forza lavoro	Tasso di disoccupazione
<code>educ_tertiary</code>	% pop. 25-64	Istruzione terziaria
<code>rnd_gdp_pct</code>	% PIL	Spesa R&S
<code>hitech_emp_pct</code>	% occupati	Occupazione high-tech
<code>broadband_pct</code>	% famiglie	Accesso banda larga

Il dataset comprende **155 regioni NUTS-2** di 23 paesi UE, suddivise in: 52 meno sviluppate, 50 in transizione, 53 più sviluppate (classi quasi bilanciate). Partizione: 75% training (116) / 25% test (39), seme `set.seed(2026)`.

Table 2: Mediane dei predittori per categoria di sviluppo (dataset completo). Il gradiente tra classi è visibile per tutte le variabili tranne la disoccupazione, che distingue soprattutto la classe meno sviluppata.

Variabile	Meno sv.	Transiz.	Più sv.
Disoccupazione (%)	9.1	8.3	5.9
Educ. terziaria (%)	23.4	36.1	43.3
R&S (% PIL)	0.7	1.2	1.7
High-tech (%)	193.2	52.9	71.9
Banda larga (%)	93.4	93.3	95.4




Figure 1: Distribuzione dei predittori per categoria di sviluppo (training set). Le regioni meno sviluppate mostrano disoccupazione elevata e bassi livelli di istruzione, R&S e digitalizzazione. La classe transizione ha posizione intermedia con ampia sovrapposizione.




Figure 2: Disoccupazione vs istruzione terziaria per categoria. La separazione tra meno sviluppate (rosso) e più sviluppate (verde) è netta; la transizione (giallo) si sovrappone a entrambe, motivando l'uso di classificatori multivariati.

3 Metodi e Selezione del Modello

Vengono applicati tre classificatori: **KNN** (non parametrico), **LDA** (frontiere lineari, covarianza comune) e **QDA** (frontiere quadratiche, covarianza per classe). Tutti i predittori sono standardizzati (z-score) prima della classificazione. Il parametro K di KNN è selezionato tramite **convalida incrociata a 10 gruppi** sul solo training set, senza mai coinvolgere il test set.




Figure 3: Errore CV a 10 gruppi per KNN al variare di K . Il minimo è in $K=12$. La curva illustra il dilemma bias-varianza: K piccoli (alta varianza) e K grandi (alto bias) producono entrambi errori elevati.

4 Risultati

Table 3: Confronto dei classificatori sul test set (39 regioni).
Metriche macro-mediate tra le tre classi.

Modello	Accuratezza	Sensitività (macro)	Specificità (macro)
KNN	0.667	0.659	0.829
LDA	0.821	0.814	0.907
QDA	0.744	0.738	0.866

LDA ottiene la migliore accuratezza (**82.1%**), superando QDA (74.4%) e KNN (66.7%). Questo indica che le classi sono linearmente separabili nello spazio dei predittori: la politica UE che definisce soglie lineari sul PIL si riflette in una struttura altrettanto lineare negli indicatori strutturali. La maggiore flessibilità di QDA non compensa il costo in varianza con questo campione. KNN soffre della maledizione della dimensionalità con soli 116 osservazioni in 5 dimensioni.




Figure 4: Matrici di confusione sul test set: KNN (sinistra), LDA (centro), QDA (destra). La classe transizione è la più difficile in tutti i modelli — è per definizione la categoria intermedia. Le regioni meno sviluppate sono classificate quasi perfettamente da LDA e QDA (profilo strutturale distinto dell'Europa orientale).




Figure 5: Spazio discriminante LDA (training set). LD1 separa le regioni meno sviluppate da quelle più sviluppate; LD2 differenzia la classe di transizione.

5 Conclusioni

Con LDA si raggiunge un'accuratezza dell'**82.1%** nel classificare le regioni NUTS-2 per categoria di sviluppo UE usando solo indicatori strutturali non-PIL. Il risultato principale è che la separazione tra classi è approssimativamente lineare: disoccupazione, istruzione e digitalizzazione congiuntamente definiscono un profilo regionale coerente con la categoria di sviluppo assegnata dall'UE. La classe *transizione* rimane la più difficile da classificare (confusa con entrambe le adiacenti), mentre le regioni *meno sviluppate* sono identificate quasi perfettamente — segnale che il divario strutturale dell'Europa orientale è profondo e multidimensionale.

Implicazioni. Il modello potrebbe monitorare la *convergenza reale*: una regione che migliora coerentemente in tutti gli indicatori strutturali si avvicina alla categoria superiore anche senza che il PIL venga misurato in tempo reale. **Limitazioni.** Il campione esclude le regioni con dati mancanti (principalmente piccole isole); l'analisi è cross-sezionale (2021) e non cattura la dinamica temporale della convergenza.