

Classificazione delle Regioni Europee per Livello di Sviluppo

Un'analisi di classificazione sui dati Eurostat NUTS-2

Martina

2026-06-28

Contents

1	Introduzione	1
2	I Dati	2
2.1	Variabili	2
2.2	Campione e distribuzione delle classi	2
2.3	Analisi esplorativa	3
3	Costruzione dei Modelli	4
3.1	Selezione di K per KNN tramite convalida incrociata	5
4	Valutazione dei Modelli	5
4.1	Accuratezza e metriche per classe	5
4.2	Matrici di confusione	6
4.3	Spazio discriminante LDA	7
5	Conclusioni	7
6	Appendice: Codice R	9

1 Introduzione

La politica di coesione dell'Unione Europea è uno dei principali strumenti di intervento per ridurre le disparità economiche e sociali tra le regioni degli Stati membri. Ogni ciclo di programmazione, l'UE classifica le regioni NUTS-2 in tre categorie — *meno sviluppate*, *in transizione* e *più sviluppate* — in base al PIL pro capite in parità di potere d'acquisto (PPS) rispetto alla media UE, e assegna i fondi strutturali di conseguenza.

Obiettivo. Costruire un modello di classificazione che predica la categoria di sviluppo di una regione NUTS-2 a partire da indicatori socioeconomici *diversi dal PIL* — disoccupazione, istruzione, innovazione, digitalizzazione — e valutarne la capacità predittiva su regioni non viste durante l’addestramento.

L’interesse pratico è duplice: da un lato verificare se e in che misura la categoria di sviluppo sia *leggibile* da questi indicatori strutturali (senza conoscere il PIL direttamente), dall’altro identificare quali dimensioni del divario regionale sono più discriminanti.

Fonte dei dati. I dati provengono dall’ufficio statistico ufficiale dell’Unione Europea, **Eurostat**, tramite il pacchetto R **eurostat** che interroga direttamente l’API Eurostat:

`https://ec.europa.eu/eurostat/api/dissemination/sdmx/2.1/data/{codice_dataset}`

I dataset utilizzati sono tutti della serie **tgs00xxx** (Regional indicators, anno di riferimento 2021) e **isoc_r_broad_h**.

2 I Dati

2.1 Variabili

Variabile Eurostat	Nome nel modello	Unità	Ruolo
tgs00006 (GDP PPS)	—	% media UE	Definisce la classe (non usato come predittore)
tgs00010	unemp_rate	%	Tasso di disoccupazione
tgs00109	educ_tertiary	% pop. 25-64	Istruzione terziaria
tgs00042	rnd_gdp_pct	% PIL	Spesa R&S
tgs00059	hitech_emp_pct	%	Occupazione high-tech
isoc_r_broad_h	broadband_pct	% famiglie	Accesso banda larga

Il PIL pro capite (PPS) è utilizzato esclusivamente per definire la variabile risposta secondo le soglie ufficiali UE ($< 75\%$ = meno sviluppata; $75\text{--}100\%$ = transizione; $> 100\%$ = più sviluppata) e viene poi rimosso dai predittori. Ciò rende il problema di classificazione non banale: i predittori misurano *dimensioni strutturali* diverse dal reddito diretto.

2.2 Campione e distribuzione delle classi

Il dataset comprende **155 regioni NUTS-2** di 23 paesi UE (anno 2021), con dati completi per tutti e cinque i predittori. La partizione è 75% training (116 regioni) e 25% test (39 regioni), con seme fisso per riproducibilità.

Table 2: Distribuzione delle classi nel dataset completo. Le classi sono quasi perfettamente bilanciate.

Classe	N regioni
Meno sviluppata	52
Transizione	50
Più sviluppata	53

2.3 Analisi esplorativa




Figure 1: Distribuzione dei predittori per categoria di sviluppo (training set). Le regioni meno sviluppate mostrano disoccupazione più alta, istruzione e R&S più basse. La classe transizione occupa una posizione intermedia ma con ampia sovrapposizione.




Figure 2: Disoccupazione vs istruzione terziaria per categoria di sviluppo. La separazione tra regioni meno sviluppate (rosso) e più sviluppate (verde) è netta, mentre le regioni in transizione (giallo) si sovrappongono a entrambe — motivando l’uso di metodi multivariati.

Table 3: Matrice di correlazione tra i predittori (training set).
Le correlazioni moderate indicano assenza di multicollinearità grave.

	Disoccup.	Educ. terz.	R&S	High-tech	Banda larga
Disoccup.	1.00	-0.01	-0.12	-0.16	-0.02
Educ. terz.	-0.01	1.00	0.43	-0.37	0.32
R&S	-0.12	0.43	1.00	-0.26	0.01
High-tech	-0.16	-0.37	-0.26	1.00	0.00
Banda larga	-0.02	0.32	0.01	0.00	1.00

3 Costruzione dei Modelli

Vengono applicati tre classificatori al problema multiclasse (3 categorie):

- **KNN** (*K-nearest neighbors*): classificatore non parametrico; il numero di vicini K è selezionato tramite convalida incrociata a 10 gruppi sul solo insieme di addestramento.

- **LDA** (*Linear Discriminant Analysis*): classificatore parametrico che assume distribuzioni gaussiane con matrice di covarianza comune alle classi e frontiere di decisione lineari.
- **QDA** (*Quadratic Discriminant Analysis*): estensione di LDA che consente matrici di covarianza diverse per classe, producendo frontiere quadratiche.

Tutti i predittori sono **standardizzati** (media 0, deviazione standard 1) prima dell'applicazione di KNN (obbligatorio per la distanza euclidea) e di LDA/QDA (per confrontabilità dei coefficienti discriminanti).

3.1 Selezione di K per KNN tramite convalida incrociata




Figure 3: Errore di convalida incrociata a 10 gruppi al variare di K (KNN). Il valore ottimale minimizza l'errore CV sul training set; il test set non viene mai coinvolto in questa fase.

La convalida incrociata seleziona $K = 12$, con errore CV medio di 0.278. La curva CV (Figura 3) mostra il tipico **dilemma bias-varianza**: per K piccoli (modello flessibile, basso bias ma alta varianza) l'errore CV è elevato; al crescere di K il modello si regolarizza e l'errore diminuisce fino al minimo, per poi aumentare di nuovo quando il modello diventa troppo rigido.

4 Valutazione dei Modelli

4.1 Accuratezza e metriche per classe

Table 4: Confronto tra i classificatori sul test set (39 regioni). Accuratezza globale e medie macro di sensitività e specificità per classe.

Modello	Accuratezza	Sensitività (media)	Specificità (media)
KNN	0.667	0.659	0.829
LDA	0.821	0.814	0.907
QDA	0.744	0.738	0.866

LDA ottiene la migliore accuratezza (82.1%) e le migliori metriche medie. Questo suggerisce che le tre classi siano approssimativamente separabili con frontiere *lineari* nello spazio dei predittori, coerentemente con la struttura delle politiche UE che definisce soglie su una scala ordinale di sviluppo. QDA (74.4%) migliora su KNN ma non supera LDA, indicando che la maggiore flessibilità di QDA non compensa il costo in varianza con questo campione. KNN (66.7%) è il meno accurato: la distanza euclidea con pochi dati in 5 dimensioni soffre della *maledizione della dimensionalità*.

4.2 Matrici di confusione




Figure 4: Matrici di confusione sul test set per KNN (sinistra), LDA (centro) e QDA (destra). La classe 'Transizione' è la più difficile da classificare in tutti i metodi, per la sua natura intermedia.

In tutti e tre i modelli, la classe *meno sviluppata* è classificata con la maggiore accuratezza (regioni dell'Europa orientale hanno profili socioeconomici distinti), mentre la classe *transizione* produce più classificazioni errate verso le classi adiacenti — un risultato interpretabile: le regioni di transizione sono per definizione quelle più simili a entrambe le categorie confinanti.

4.3 Spazio discriminante LDA




Figure 5: Proiezione delle regioni di training nello spazio dei due discriminanti lineari LDA. LD1 separa principalmente le regioni meno sviluppate da quelle più sviluppate; LD2 differenzia la classe di transizione.

5 Conclusioni

L'analisi mostra che è possibile predire la categoria di sviluppo EU di una regione NUTS-2 con buona accuratezza (**82.1% con LDA**) usando esclusivamente indicatori strutturali non direttamente legati al PIL: disoccupazione, istruzione, R&S, occupazione high-tech e connettività a banda larga.

Il modello LDA risulta superiore agli altri, confermando che la struttura del problema è approssimativamente lineare nello spazio di questi predittori — coerentemente con la logica della politica di coesione UE, che definisce soglie lineari sul PIL per assegnare le categorie.

Le principali difficoltà di classificazione riguardano le regioni di *transizione*, che per costruzione sono quelle più simili alle altre due categorie. La classe *meno sviluppata* è invece classificata quasi perfettamente: le regioni dell'Europa orientale presentano profili strutturalmente distinti da quelli dell'Europa occidentale.

Implicazioni. Un modello di questo tipo potrebbe essere utilizzato per monitorare *convergenza reale*: una regione che viene riclassificata correttamente da indicatori strutturali (senza usare il PIL) sta mostrando una coerenza tra crescita economica e sviluppo dei capitali umano e tecnologico. Una

misclassificazione sistematica potrebbe invece segnalare disallineamenti strutturali che richiedono politiche mirate.

Limitazioni. Il campione è limitato a 155 regioni con dati completi (alcune regioni periferiche o di piccole dimensioni sono escluse per mancanza di dati). La classificazione è basata su un singolo anno (2021) e non cattura la dinamica temporale del processo di convergenza.

6 Appendice: Codice R

```
# 01_load_data.R
# Download Eurostat data for EU NUTS-2 regions (2021, most recent complete year).
# Response: Cohesion Policy development category derived from GDP per capita (PPS)
#   - "meno_sviluppata" (less developed): GDP < 75% EU average
#   - "transizione"     (transition):      75% GDP 100%
#   - "piu_sviluppata"  (more developed):  GDP > 100%
# Predictors: unemployment, tertiary education, R&D expenditure, employment in
#             high-tech, broadband access - indicators NOT used to define the class.
#
# Source: Eurostat via eurostat R package (https://ec.europa.eu/eurostat)
# Reference datasets: tgs00006, tgs00010, tgs00109, tgs00042, tgs00059, isoc_r_broad_h

library(eurostat)
library(dplyr)

set.seed(2026)
dir.create("data", showWarnings = FALSE)
dir.create("output", showWarnings = FALSE)

fetch <- function(code, value_col, year = 2021) {
  message("Fetching ", code, "...")
  df <- tryCatch(
    get_eurostat(code, time_format = "num", cache = TRUE) %>%
      filter(TIME_PERIOD == year, nchar(geo) == 4) %>% # NUTS-2: 4-char code
      group_by(geo) %>%
      summarise(!value_col := mean(values, na.rm = TRUE), .groups = "drop"),
    error = function(e) { message(" ", e$message); NULL }
  )
  if (!is.null(df)) message(" → ", nrow(df), " regions")
  df
}

# GDP per capita in PPS (% of EU average) - defines the response class
gdp_raw <- tryCatch(
  get_eurostat("tgs00006", time_format = "num", cache = TRUE),
  error = function(e) stop("Cannot fetch GDP data: ", e$message)
)
gdp <- gdp_raw %>%
  filter(TIME_PERIOD == 2021, nchar(geo) == 4) %>%
  group_by(geo) %>%
  summarise(gdp_pps_pct = mean(values, na.rm = TRUE), .groups = "drop")
message("GDP: ", nrow(gdp), " NUTS-2 regions")

# Predictors
unemp <- fetch("tgs00010", "unemp_rate") # unemployment rate (%)
```

```

educ    <- fetch("tgs00109",      "educ_tertiary")    # tertiary education, % pop 25-64
rnd      <- fetch("tgs00042",      "rnd_gdp_pct")      # R&D expenditure % GDP
hitech  <- fetch("tgs00059",      "hitech_emp_pct")    # high-tech employment %
broad   <- fetch("isoc_r_broad_h", "broadband_pct")    # broadband households %

# Join all
datasets <- Filter(Negate(is.null), list(gdp, unemp, educ, rnd, hitech, broad))
regions  <- Reduce(function(a, b) inner_join(a, b, by = "geo"), datasets)

# Add country code and drop non-EU / overseas territories
regions <- regions %>%
  mutate(country = substr(geo, 1, 2)) %>%
  filter(
    country %in% c("AT", "BE", "BG", "CY", "CZ", "DE", "DK", "EE", "EL", "ES",
                  "FI", "FR", "HR", "HU", "IE", "IT", "LT", "LU", "LV", "MT",
                  "NL", "PL", "PT", "RO", "SE", "SI", "SK"),
    !is.na(gdp_pps_pct)
  )

# Define 3-class response from GDP per capita (PPS % of EU average)
regions <- regions %>%
  mutate(
    dev_class = case_when(
      gdp_pps_pct < 75 ~ "meno_sviluppata",
      gdp_pps_pct <= 100 ~ "transizione",
      TRUE ~ "piu_sviluppata"
    ),
    dev_class = factor(dev_class,
                      levels = c("meno_sviluppata", "transizione", "piu_sviluppata"))
  )

# Drop GDP (it defines the class - must not be a predictor)
predictors <- c("unemp_rate", "educ_tertiary", "rnd_gdp_pct", "hitech_emp_pct", "broadband_pct")
aq <- regions %>% select(geo, country, dev_class, all_of(predictors))

# Remove regions with too many NAs in predictors
aq <- aq %>% filter(rowSums(is.na(select(., all_of(predictors)))) <= 1)

# Impute remaining single NAs with column median (within class)
for (col in predictors) {
  med <- median(aq[[col]], na.rm = TRUE)
  aq[[col]][is.na(aq[[col]])] <- med
}

stopifnot(nrow(aq) >= 100, !anyNA(aq))

write.csv(aq, "data/regions_raw.csv", row.names = FALSE)

```

```

write.csv(regions, "data/regions_full.csv", row.names = FALSE)

# Train/test split 75/25
n      <- nrow(aq)
train_idx <- sample(seq_len(n), size = floor(0.75 * n))
train    <- aq[train_idx, ]
test     <- aq[-train_idx, ]

write.csv(train, "data/regions_train.csv", row.names = FALSE)
write.csv(test,  "data/regions_test.csv",  row.names = FALSE)

cat(sprintf("\nDataset: %d regioni NUTS-2  (%d train / %d test)\n", n, nrow(train), nrow(test)))
cat("Distribuzione classi:\n"); print(table(aq$dev_class))
cat("\nPaesi presenti:", length(unique(aq$country)), "\n")
cat("Predittori:", paste(predictors, collapse=", "), "\n")

# 02_edu.R - Exploratory analysis of EU NUTS-2 regional development data

library(dplyr)
library(ggplot2)
library(tidyr)

dir.create("figures", showWarnings = FALSE)

train <- read.csv("data/regions_train.csv", stringsAsFactors = FALSE)
train$dev_class <- factor(train$dev_class,
                          levels = c("meno_sviluppata", "transizione", "piu_sviluppata"))

pred_labels <- c(
  unemp_rate      = "Disoccupazione (%)",
  educ_tertiary   = "Istruzione terziaria (%)",
  rnd_gdp_pct     = "Spesa R&S (% PIL)",
  hitech_emp_pct  = "Impiego high-tech (%)",
  broadband_pct   = "Banda larga famiglie (%)"
)
class_colors <- c(meno_sviluppata = "#d73027",
                  transizione     = "#fee08b",
                  piu_sviluppata  = "#1a9850")

# Boxplots per predictor x class
long <- train %>%
  select(dev_class, names(pred_labels)) %>%
  pivot_longer(-dev_class, names_to = "variable", values_to = "value") %>%
  mutate(variable = factor(variable, levels = names(pred_labels),
                           labels = pred_labels))

p_box <- ggplot(long, aes(dev_class, value, fill = dev_class)) +

```

```

geom_boxplot(outlier.size = 0.8, alpha = 0.85) +
facet_wrap(~variable, scales = "free_y", ncol = 3) +
scale_fill_manual(values = class_colors, guide = "none") +
scale_x_discrete(labels = c("Meno sv.", "Transiz.", "Più sv.)) +
labs(x = NULL, y = NULL,
      title = "Distribuzione dei predittori per categoria di sviluppo (training set)") +
theme_minimal(base_size = 10) +
theme(strip.text = element_text(size = 8))
ggsave("figures/boxplots.png", p_box, width = 8, height = 5, dpi = 150)

# Scatter: disoccupazione vs istruzione, colorato per classe
p_scatter <- ggplot(train, aes(unemp_rate, educ_tertiary, color = dev_class)) +
  geom_point(size = 2, alpha = 0.8) +
  scale_color_manual(values = class_colors,
                    labels = c("Meno sviluppata", "Transizione", "Più sviluppata"),
                    name = "Categoria") +
  labs(x = "Tasso di disoccupazione (%)",
       y = "Istruzione terziaria (% pop. 25-64)",
       title = "Disoccupazione vs Istruzione per categoria di sviluppo") +
  theme_minimal()
ggsave("figures/scatter_unemp_educ.png", p_scatter, width = 7, height = 4.5, dpi = 150)

# Correlation matrix
cor_mat <- train %>%
  select(names(pred_labels)) %>%
  cor(use = "complete.obs")

# Save as CSV for report
write.csv(round(cor_mat, 3), "output/cor_matrix.csv")

cat("EDA complete. Figures: boxplots.png, scatter_unemp_educ.png\n")
cat("\nCorrelazioni principali:\n")
print(round(cor_mat, 2))

```

```

# 03_modeling.R
# Classification of EU NUTS-2 regions by development level.
# Methods: KNN (K selected by 10-fold CV), LDA, QDA.
# All hyperparameter selection is done on the training set only.

library(dplyr)
library(class) # knn()
library(MASS) # lda(), qda()
library(caret) # confusionMatrix()

set.seed(2026)

train <- read.csv("data/regions_train.csv", stringsAsFactors = FALSE)

```

```

test <- read.csv("data/regions_test.csv", stringsAsFactors = FALSE)

lvls <- c("meno_sviluppata", "transizione", "piu_sviluppata")
train$dev_class <- factor(train$dev_class, levels = lvls)
test$dev_class <- factor(test$dev_class, levels = lvls)

predictors <- c("unemp_rate", "educ_tertiary", "rnd_gdp_pct", "hitech_emp_pct", "broadband_pct")

X_train <- scale(train[, predictors])
X_test <- scale(test[, predictors],
                center = attr(X_train, "scaled:center"),
                scale = attr(X_train, "scaled:scale"))
y_train <- train$dev_class
y_test <- test$dev_class

dir.create("output", showWarnings = FALSE)

# 1. KNN - select K by 10-fold cross-validation
K_cv <- 10
folds <- sample(rep(1:K_cv, length.out = nrow(train)))
K_grid <- 1:25

cv_errors <- sapply(K_grid, function(k) {
  errs <- sapply(1:K_cv, function(f) {
    tr_x <- X_train[folds != f, , drop = FALSE]
    va_x <- X_train[folds == f, , drop = FALSE]
    tr_y <- y_train[folds != f]
    va_y <- y_train[folds == f]
    pred <- knn(tr_x, va_x, tr_y, k = k)
    mean(pred != va_y)
  })
  mean(errs)
})

cv_results <- data.frame(K = K_grid, cv_error = cv_errors)
write.csv(cv_results, "output/knn_cv_results.csv", row.names = FALSE)

best_K <- K_grid[which.min(cv_errors)]
cat(sprintf("KNN - best K = %d (CV error = %.3f)\n", best_K, min(cv_errors)))

# Final KNN prediction on test set
knn_pred <- knn(X_train, X_test, y_train, k = best_K)

# 2. LDA
lda_fit <- lda(dev_class ~ ., data = data.frame(dev_class = y_train, X_train))
lda_pred <- predict(lda_fit, newdata = data.frame(X_test))$class

```

```

# 3. QDA
qda_fit <- qda(dev_class ~ ., data = data.frame(dev_class = y_train, X_train))
qda_pred <- predict(qda_fit, newdata = data.frame(X_test))$class

# 4. Metrics
metrics <- function(pred, actual, name) {
  cm <- confusionMatrix(pred, actual)
  acc <- cm$overall["Accuracy"]
  # Per-class sensitivity and specificity (macro average)
  sens <- mean(cm$byClass[, "Sensitivity"], na.rm = TRUE)
  spec <- mean(cm$byClass[, "Specificity"], na.rm = TRUE)
  list(name = name, cm = cm, accuracy = acc, sensitivity = sens, specificity = spec)
}

res_knn <- metrics(knn_pred, y_test, "KNN")
res_lda <- metrics(lda_pred, y_test, "LDA")
res_qda <- metrics(qda_pred, y_test, "QDA")

results <- list(knn = res_knn, lda = res_lda, qda = res_qda)
saveRDS(results, "output/classification_results.rds")
saveRDS(lda_fit, "output/lda_fit.rds")
saveRDS(qda_fit, "output/qda_fit.rds")

comparison <- bind_rows(lapply(results, function(r)
  data.frame(Modello = r$name,
             Accuratezza = round(r$accuracy, 3),
             Sensitivita = round(r$sensitivity, 3),
             Specificita = round(r$specificity, 3))
))
write.csv(comparison, "output/model_comparison.csv", row.names = FALSE)

cat("\n Confronto modelli (test set) \n")
print(comparison)

cat("\n Matrice di confusione KNN \n"); print(res_knn$cm$table)
cat("\n Matrice di confusione LDA \n"); print(res_lda$cm$table)
cat("\n Matrice di confusione QDA \n"); print(res_qda$cm$table)

```

```

# 04_evaluation.R - Plots and detailed evaluation of classification models

```

```

library(ggplot2)
library(dplyr)
library(tidyr)
library(MASS)

dir.create("figures", showWarnings = FALSE)

```

```

results <- readRDS("output/classification_results.rds")
cv_res <- read.csv("output/knn_cv_results.csv")
lda_fit <- readRDS("output/lda_fit.rds")

# CV error curve for KNN
best_K <- cv_res$K[which.min(cv_res$cv_error)]

p_cv <- ggplot(cv_res, aes(K, cv_error)) +
  geom_line(color = "steelblue") +
  geom_point(size = 1.5, color = "steelblue") +
  geom_vline(xintercept = best_K, linetype = "dashed", color = "red") +
  annotate("text", x = best_K + 1.2, y = max(cv_res$cv_error) * 0.97,
    label = paste0("K=", best_K), color = "red", hjust = 0, size = 3.5) +
  labs(title = "Errore di convalida incrociata per KNN",
    x = "K (numero di vicini)", y = "Errore CV medio (10 fold)") +
  theme_minimal()
ggsave("figures/knn_cv_curve.png", p_cv, width = 6, height = 3.5, dpi = 150)

# Confusion matrices as heatmaps
plot_cm <- function(cm_table, title) {
  df <- as.data.frame(cm_table)
  colnames(df) <- c("Predetto", "Reale", "N")
  lvl_labels <- c("Meno sv.", "Transiz.", "Più sv.")
  df$Predetto <- factor(df$Predetto,
    levels = c("meno_sviluppata", "transizione", "piu_sviluppata"),
    labels = lvl_labels)
  df$Reale <- factor(df$Reale,
    levels = c("meno_sviluppata", "transizione", "piu_sviluppata"),
    labels = lvl_labels)
  ggplot(df, aes(Reale, Predetto, fill = N)) +
    geom_tile(color = "white") +
    geom_text(aes(label = N), size = 5) +
    scale_fill_gradient(low = "white", high = "#2166ac", name = "N") +
    labs(title = title, x = "Classe reale", y = "Classe predetta") +
    theme_minimal() +
    theme(axis.text = element_text(size = 9))
}

p_knn <- plot_cm(results$knn$cm$table, "Matrice di confusione - KNN")
p_lda <- plot_cm(results$lda$cm$table, "Matrice di confusione - LDA")
p_qda <- plot_cm(results$qda$cm$table, "Matrice di confusione - QDA")
ggsave("figures/cm_knn.png", p_knn, width = 5, height = 4, dpi = 150)
ggsave("figures/cm_lda.png", p_lda, width = 5, height = 4, dpi = 150)
ggsave("figures/cm_qda.png", p_qda, width = 5, height = 4, dpi = 150)

# LDA discriminant space plot (LD1 vs LD2)
train <- read.csv("data/regions_train.csv", stringsAsFactors = FALSE)

```

```

predictors <- c("unemp_rate", "educ_tertiary", "rnd_gdp_pct", "hitech_emp_pct", "broadband_pct")
X_sc <- scale(train[, predictors])
lda_scores <- predict(lda_fit, newdata = data.frame(X_sc))$x

class_colors <- c(meno_sviluppata = "#d73027",
                  transizione     = "#e6a817",
                  piu_sviluppata   = "#1a9850")

df_ld <- data.frame(LD1 = lda_scores[,1], LD2 = lda_scores[,2],
                   classe = factor(train$dev_class,
                                   levels = c("meno_sviluppata", "transizione", "piu_sviluppata")))
p_ld <- ggplot(df_ld, aes(LD1, LD2, color = classe)) +
  geom_point(size = 2, alpha = 0.85) +
  scale_color_manual(values = class_colors,
                    labels = c("Meno sviluppata", "Transizione", "Più sviluppata"),
                    name = "Categoria") +
  labs(title = "Spazio discriminante LDA (training set)",
       x = "Primo discriminante lineare (LD1)",
       y = "Secondo discriminante lineare (LD2)") +
  theme_minimal()
ggsave("figures/lda_space.png", p_ld, width = 7, height = 4.5, dpi = 150)

cat("Evaluation plots saved.\n")

```